



澳門城市大學  
Universidade da Cidade de Macau  
City University of Macau

## BITMZ033 機器學習期末報告

### 【英國道路交通事故嚴重程度分類預測】

小組 I D Group ID : 16

姓名 Name : D23090600351 呂維懿  
D23090600680 李東曉  
D23090600127 李柏熹

院系 Faculty : 數據科學學院

課程 Program : 機器學習

指導教師 Supervisor : 吳世卿、蔡劍平助理教授

2026 年 4 月 26 日

# 第一章 問題與背景描述

## 1.1 研究背景與問題意義

道路交通事故是全球公共衛生面臨的重大挑戰之一。根據世界衛生組織（WHO）發佈的《全球道路安全狀況報告》，全球道路交通死亡人數每年約為 135 萬人，道路交通傷害也是 5 至 29 歲人群的重要死因之一（World Health Organization, 2018）。在英國，儘管道路安全狀況持續改善，Department for Transport（DfT）基於 STATS19 系統發佈的道路安全開放數據仍顯示，2005 至 2015 年間記錄了超過 178 萬起人身傷害道路交通事故，其中包括約 2.3 萬起致命事故和 24.2 萬起嚴重傷害事故（Department for Transport, 2025）。這些事故不僅造成不可估量的人身傷害，也對公共衛生系統、保險行業和社會經濟產生持續負擔。

在這一背景下，準確預測事故嚴重程度具有直接的實際應用價值。對於急救調度系統而言，若能在接到事故報案的第一時間初步判斷其嚴重程度，便可實現資源的分級調度。例如將高級生命支持團隊（ALS team）優先派往高嚴重度事故現場，而將普通救護車分配給輕微事故。其次，對於保險行業，事故嚴重程度的預測模型可輔助風險評估和保費定價。除了上面說到的兩個方面，識別高風險事故模式有助於針對性地改善道路基礎設施和安全政策。

然而，準確預測事故嚴重程度並非易事。它的核心困難在於目標變數的極端類別不平衡（Fatal（致命）事故僅占全部事故約 1.29%，而 Slight（輕微）事故約占 85.11%）。在這類不平衡分類問題中，單純追求 Accuracy 往往會掩蓋少數類別識別失敗，因此需要同時關注 Macro F1、per-class Recall 和 Precision 等指標（He & Garcia, 2009）。在我們本次的研究中，一個簡單地將所有事故預測為“輕微”的樸素模型即可獲得約 85% 的準確率，卻無法識別任何致命事故；因此，如何在極端不平衡條件下有效識別高嚴重度事故，構成了本研究的核心技術挑戰。

## 1.2 研究問題定義與預測場景

圍繞上述背景，研究的核心問題便是在僅使用事故發生初期即可獲得的資訊時，機器學習模型能否有效區分 Fatal、Serious 與 Slight 三類事故嚴重程度。

在這個問題的基礎上，我們進一步分析兩方面內容：一是環境、車輛和時間因素中哪些變數與嚴重事故的關係最穩定；二是事故樣本是否能夠形成具有解釋意義的分群，以及這些分群是否能補充監督模型的預測資訊。

我們假設模型應用於事故剛發生、急救中心接到初步報案的時刻。在這個時間點上，可獲取的資訊主要包括事故發生的時間和地點屬性（道路類型、限速、城鄉區域）、當時的環境條件（天氣、光照、路面狀況），以及由報案人初步描述的涉事車輛類型和數量。所以只有事故發生當下可觀測的特徵被允許進入模型，所有事後盤點的結果變數（如最終傷亡人數、傷亡等級等）均被嚴格排除。

這樣處理可以避免將事後結果資訊提前提供給模型，也使實驗設定更接近事故初報階段的實際條件。

根據上述問題我們設計了描述任務與預測任務兩個板塊來解決，但這並不是兩個孤立板塊。（1）首先通過聚類識別事故類型原型，再將 `Cluster_ID` 作為衍生特徵輸入分類模型，以檢驗事故原型是否包含超越原始特徵的結構化資訊；（2）我們按聚類結果分析預測錯誤，進一步識別模型在不同事故場景下的系統性弱點。

### 1.3 數據集描述

我們使用英國交通部 (DfT) 公開發佈的 STATS19 數據集，涵蓋 2005 至 2015 年間英國全境記錄的道路交通事故數據。該數據來自英國警方通過 STATS19 標準化表格記錄並提交的道路交通事故資訊，包含事故、車輛和傷亡人員三個層面的結構化數據 (Department for Transport, 2025)。

數據集由三個 CSV 檔組成，並通過唯一識別字 `Accident_Index` 關聯。*Accidents0515.csv* 是事故主表，原始包含 1,780,653 條記錄和 32 個字段，記錄事故發生的時間、地點、道路條件、光照、天氣以及事故嚴重程度等資訊。*Vehicles0515.csv* 記錄涉事車輛資訊，共 3,262,270 條記錄和 22 個字段，包括車輛類型、駕駛員年齡、車輛年齡和發動機排量等。由於一起事故可能涉及多輛車輛，車輛表需要先聚合到事故層級，再與事故主表連接。*Casualties0515.csv* 記錄傷亡人員資訊，但其中的傷亡人數和傷亡等級屬於事故後果，不適合用於事故初報階段的嚴重程度預測，因此不進入建模流程。

目標變數為 `Accident_Severity`，共有三個類別：1=Fatal、2=Serious、3=Slight。原始事故主表中，Fatal 事故 22,998 起，占 1.29%；Serious 事故 242,080 起，占 13.60%；Slight 事故 1,515,575 起，占 85.11%。後續預處理刪除了 151 條 `Time` 字段為空、無法解析事故發生時段的記錄，因此建模數據集包含 1,780,502 條事故記錄。圖 1 展示的是清洗後的類別分佈：Fatal 22,996 起、Serious 242,052 起、Slight 1,515,454 起。兩種口徑下的類別比例幾乎一致，均呈現約 85:14:1 的極端不平衡結構。




圖 1 事故嚴重程度類別分佈（刪除 `Time` 缺失記錄後的建模數據集， $n=1,780,502$ ）

需要說明的是，STATS19 數據中的許多類別變數並不是以文字形式存儲，而是採用整數編碼。例如，天氣條件、光照條件、道路類型和路面狀況等字段都由數字代碼表示。在這些編碼字段中，-1 通常表示該項資訊缺失、未知或超出有效取值範圍，而不是一個具有實際含義的事故類別。數據集附帶的 *contextCSVs* 查找表提供了編碼與文字標籤之間的對應關係，後續特徵解釋和圖表展示均基於這些映射完成。

## 第二章 數據預處理

### 2.1 數據載入與整合策略

數據整合以 *Accidents0515.csv* 為主表進行。該表以每起事故為一條記錄，包含事故發生的時間、地點、道路環境、天氣、光照以及嚴重程度等資訊，正好對應監督學習中的樣本單位。因此，後續建模始終保持“一行代表一起事故”的結構。

*Vehicles0515.csv* 通過 *Accident\_Index* 與事故主表關聯，但不能直接逐行合併。由於一起事故可能涉及多輛車輛，直接連接會使同一事故重複出現，導致多車事故在訓練中被賦予更高權重。為避免這一問題，車輛表先按 *Accident\_Index* 聚合到事故層級，再與事故主表左連接。聚合後的變數包括涉事車輛數量、是否包含摩托車、是否包含重型車輛、是否存在年輕駕駛員、駕駛員平均年齡、車輛平均年齡和發動機平均排量等。

*Casualties0515.csv* 沒有進入建模流程。該表記錄傷亡人數和傷亡等級等事故後果資訊，而本研究的預測場景設定在事故剛發生、調度中心接到初步報案的時刻。如果使用這些變數，模型會提前獲得事後結果資訊，形成數據洩漏。因此，傷亡表僅用於理解數據結構，不參與特徵構建。

數據載入過程中還需要處理兩個技術細節。第一是 *Vehicles0515.csv* 檔存在 2015 年 schema 變更，即從 2015 年數據行起增加了第 23 列（原文件僅定義 22 列），導致 pandas 默認解析器靜默丟棄 258,845 條記錄（占 7.9%）。我們通過 `callable on_bad_lines` 參數截斷多餘列完整恢復了這些數據；另一個是兩個主 CSV 檔均包含 UTF-8 BOM 位元組序標記，需使用 `encoding='utf-8-sig'` 正確處理以避免首列名污染。

### 2.2 缺失值與異常值處理

#### 2.2.1 缺失值識別

STATS19 數據中，許多編碼字段使用 -1 表示缺失、未知或超出有效取值範圍。初始探索性分析發現，-1 出現在 13 個字段中。其中缺失比例較高的字段包括 *2nd\_Road\_Class* (41.16%)、*Junction\_Control* (36.02%)、*Mean\_Vehicle\_Age* (15.34%) 和 *Mean\_Engine\_Capacity* (13.68%)。這些缺失並非都適合用同一種方式處理，因此需要根據缺失比例、字段含義和是否存在洩漏風險分別判斷。

#### 2.2.2 缺失處理策略

對缺失值的處理根據缺失比例、缺失原因以及是否存在洩漏風險分別確定。

缺失率較高且缺失本身具有結構性含義的變數，我們沒有進行數值填補，而是直接刪除。*Junction\_Control* (36.02%缺失) 和 *2nd\_Road\_Class* (41.16%缺失) 的缺失主要源於事故不在路口發生時字段本身不適用。若對這類 MNAR (Missing

Not At Random) 數據進行填補，會引入大量偽造值並扭曲特徵分佈。另一種方案是將缺失本身作為類別編碼，但它會與 Junction\_Detail 字段產生冗餘，因此最終刪除這兩列。

另一類需要刪除的變數是可能包含事後判斷資訊的字段。這類字段例如 Did\_Police\_Officer\_Attend\_Scene\_of\_Accident 雖然缺失率極低 (0.02%)，但員警是否到場很可能受到事故嚴重程度影響，保留該字段會引入與目標變數因果相關的事後信號，違反“報案時刻可獲取資訊”的預測場景假設。

對於中低缺失率的數值型特徵我們選擇在 Pipeline 內部使用中位數填補。如 Mean\_Driver\_Age (3.88% 缺失)、Mean\_Vehicle\_Age (15.34% 缺失) 和 Mean\_Engine\_Capacity (13.68% 缺失)，選擇中位數而非均值，是因為這些特徵分佈右偏且存在極端值，中位數對偏態分佈更穩健。沒用使用 KNN Imputer 是因為在數據量達到百萬級的情況下  $O(n^2)$  計算複雜度不可行。所有填補操作的 fit 步驟只在訓練集或交叉驗證訓練折上執行，測試集僅進行 transform，從而通過 sklearn Pipeline 在架構層面控制洩漏風險 (Pedregosa et al., 2011)。

而對於低缺失率的類別型特徵，如 Weather\_Conditions (0.01% 缺失) 和 Road\_Surface\_Conditions (0.14% 缺失)，本文在 Pipeline 內部使用眾數填補。

### 2.2.3 異常值處理

異常值處理主要依據 STATS19 字段的合法取值範圍和道路交通常識設定截斷邊界。為了使某一特徵的異常值不應導致該記錄的其他有效特徵資訊丟失，我們採用截斷而非刪除行。具體截斷規則包括：Speed\_limit 截斷至 [10, 70] mph (英國合法限速範圍，0 mph 的 1 條記錄為數據錄入錯誤)；Mean\_Driver\_Age 截斷至 [16, 90] (英國法定駕駛年齡下限至合理上限)；Mean\_Engine\_Capacity 截斷至 [50, 8000] cc；Number\_of\_Vehicles 截斷至 [1, 20]。

### 2.2.4 列刪除匯總

經過上述清洗流程，共刪除 12 個列：

| 刪除字段                                        | 刪除原因                             |
|---------------------------------------------|----------------------------------|
| Number_of_Casualties                        | 屬於事故發生後的結果資訊，若用於預測事故嚴重程度會造成數據洩漏。 |
| Did_Police_Officer_Attend_Scene_of_Accident | 員警是否到場可能受到事故嚴重程度影響，存在反向因果洩漏風險。   |
| Accident_Index                              | 僅作為事故唯一識別字使用，不具有可泛化的預測意義。        |
| 1st_Road_Number                             | 道路編號過於細緻，容易引入局部記憶，泛化能力較弱。        |
| Police_Force                                | 與地區變數存在較強重疊，保留後容易造成地理資訊冗餘。       |
| Local_Authority_(Highway)                   | 字串型地區字段，與數值型行政區變數資訊重複。           |

| 刪除字段                      | 刪除原因                                             |
|---------------------------|--------------------------------------------------|
| LSOA_of_Accident_Location | 過細粒度的地理 ID，維度高且難以直接泛化。                           |
| Location_Easting_OSGR     | 原始網格座標，不直接進入監督模型；地理資訊由 Local_Authority 頻率編碼間接表示。 |
| Location_Northing_OSGR    | 原始網格座標，不直接進入監督模型；地理資訊由 Local_Authority 頻率編碼間接表示。 |
| 2nd_Road_Class            | 結構性缺失比例較高，主要在非路口場景下不適用。                          |
| 2nd_Road_Number           | 與第二道路資訊相關，存在結構性缺失，且對監督建模貢獻有限。                    |
| Junction_Control          | 缺失率約 36%，且與路口相關變數存在一定重疊。                         |

表 1 數據清洗階段刪除字段及原因匯總

最終數據集：1,780,502 行 × 28 列（含 6 個車輛聚合特徵），丟失 151 行（僅因 Time 字段為空字元串，占 0.008%，可忽略）。

## 2.3 特徵工程

### 2.3.1 時間特徵

從已解析的 Hour、Day\_of\_Week、Month 字段派生三個新特徵：

- **Time\_Period:** 將 Hour 分箱為 5 個時段（dawn 0-5 / morning\_rush 6-9 / daytime 10-15 / evening\_rush 16-18 / night 19-23）。分箱依據是不同時段反映截然不同的駕駛風險特徵。凌晨時段（dawn）關聯疲勞駕駛和酒駕，早晚高峰關聯通勤高交通量，夜間關聯視線不佳。原始 Hour 列保留，因為樹模型可學習到與預設分箱不完全一致的最優分裂點。
- **Is\_Weekend:** Day\_of\_Week  $\in \{1=\text{Sunday}, 7=\text{Saturday}\}$ 。週末駕駛模式與工作日顯著不同（更多休閒出行、酒精相關風險增加）。
- **Season:** Month 映射為四季（冬 12-2 / 春 3-5 / 夏 6-8 / 秋 9-11），反映日照時長和天氣條件的季節性變化對事故風險的影響。

### 2.3.2 二值風險特徵

為增強模型對關鍵風險條件的識別能力，我們將部分多類別變數轉化為更直接的二值風險特徵：

- **Is\_Dark:** Light\_Conditions  $\in \{4,5,6,7\}$ （包括有燈/無燈/未知光照條件下的所有黑暗類別）。陽性率 26.74%。該特徵主要用於區分視線是否受限，而不同黑暗子類別間的差異遠小於“白天 vs 黑暗”的整體對比。

- **Bad\_Weather:** Weather\_Conditions  $\notin \{1=Fine\}$ 。陽性率 20.07%。將所有非晴好天氣（雨、雪、霧、強風等）統一標記為"天氣不利"。
- **Wet\_Road:** Road\_Surface\_Conditions  $\notin \{1=Dry\}$ 。陽性率 31.03%。包含濕滑、積雪、結冰、洪水等所有非乾燥路面，捕獲"路面附著力受損"的整體信號。選擇不僅限於 code=2（濕滑），因為積雪和結冰同樣降低抓地力。
- **At\_Junction:** Junction\_Detail  $\neq 0$ 。陽性率 59.76%。標記事故是否發生在路口或路口 20 米範圍內。
- **Is\_Rural:** Urban\_or\_Rural\_Area = 2。陽性率 35.61%。鄉村道路缺乏照明、路肩保護和交通管理設施。

上述二值特徵並未替代原始類別列，而是與源變數同時保留在特徵集中。因為二值特徵為 Logistic Regression 提供了最有效的主對比信號（LR 無法自動從多類別編碼中提取二值對比），而原始多水準列為樹模型保留了更細粒度的分裂資訊（如"有燈黑暗"vs"無燈黑暗"的區別）。L2 正則化可有效處理由此引入的冗餘。

### 2.3.3 交互特徵

基於領域知識構造三個反映複合風險的交互特徵：

- **Dark\_And\_Wet** = Is\_Dark  $\times$  Wet\_Road（陽性率 12.36%）：夜間濕滑路面——視線受限與制動距離增大的複合風險。
- **Rural\_High\_Speed** = Is\_Rural  $\times$  (Speed\_limit  $\geq 60$ )（陽性率 21.41%）：鄉村高速路段——缺乏照明、路肩和護欄保護的高速行駛場景。
- **Dark\_Rural** = Is\_Dark  $\times$  Is\_Rural（陽性率 9.41%）：無路燈的鄉村黑暗路段——城市黑暗有路燈緩解，鄉村黑暗則是絕對的視線喪失。

構造交互特徵的原因在於，Logistic Regression 默認各特徵對 log-odds 的影響是加法形式，難以自動表達多種風險條件疊加後的效應。例如，黑暗、濕滑和鄉村道路單獨出現時風險有限，但同時出現時可能顯著提高嚴重事故概率。

### 2.3.4 地理特徵處理

Local\_Authority\_(District)字段包含 416 個唯一行政區編碼，面臨高基數類別變數的處理挑戰。One-Hot 編碼會引入約 416 個稀疏列，導致維度爆炸和過擬合風險。Target Encoding 雖資訊量更大，但直接使用會洩漏目標變數資訊。

我們採用**頻率編碼**，將每個行政區映射為其在訓練集中的事故占比。這種編碼方式完全不涉及目標變數值（僅使用事故計數的相對頻率），因此不存在洩漏風險。它捕獲了"某些區域事故更密集"的地理信號，作為低風險、低複雜度的地理代理變數。未在訓練集中出現的行政區使用全局均值（ $\approx 0.0024$ ）作為回退值。頻率映射在訓練集上計算，測試集和時間 holdout 集使用訓練集派生的映射表進行變換。

### 2.3.5 最終特徵集

經過特徵工程後，監督模型實際輸入 36 個特徵如下表：



| 特徵類型  | 數量 | 特徵名稱                                                                                                                                                                                                                                                                             |
|-------|----|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 數值型特徵 | 10 | Speed_limit、Number_of_Vehicles、Hour、Year、Month、Day、Mean_Driver_Age、Mean_Vehicle_Age、Mean_Engine_Capacity、LA_Frequency                                                                                                                                                            |
| 二值型特徵 | 12 | Is_Weekend、Is_Dark、Bad_Weather、Wet_Road、At_Junction、Is_Rural、Has_Motorcycle、Has_Heavy_Vehicle、Has_Young_Driver、Dark_And_Wet、Rural_High_Speed、Dark_Rural                                                                                                                          |
| 類別型特徵 | 14 | Day_of_Week、1st_Road_Class、Road_Type、Junction_Detail、Light_Conditions、Weather_Conditions、Road_Surface_Conditions、Urban_or_Rural_Area、Pedestrian_Crossing-Human_Control、Pedestrian_Crossing-Physical_Facilities、Special_Conditions_at_Site、Carriageway_Hazards、Time_Period、Season |
| 合計    | 36 | —                                                                                                                                                                                                                                                                                |

表 2 監督模型輸入特徵構成匯總

需要說明的是，DataFrame 中另保留 Longitude 和 Latitude 兩列，因此進入 ColumnTransformer 前共有 38 列。但這兩列不作為監督學習特徵，在預處理階段通過 remainder='drop' 排除，僅用於空間探索和聚類相關分析。

特徵間的相關性分析（見圖 2）顯示，二值風險特徵與其源列之間存在預期的中等相關，而交互特徵與嚴重程度的關聯模式（見圖 3）也支持特徵工程的有效性。




圖 2 主要數值與二值風險特徵的 Pearson 相關矩陣




圖 3 關鍵特徵在不同事故嚴重程度下的分佈差異

## 2.4 按模型類型分流的預處理策略

STATS19 中大量變數以整數編碼表示類別，但這些整數不代表有序關係。不同模型對此有根本不同的數學要求，因此我們設計了分流式預處理 Pipeline：

| 模型                   | 類別變數處理                                                        | 數值/二值變數處理                       | 輸出維度 |
|----------------------|---------------------------------------------------------------|---------------------------------|------|
| Logistic Regression  | 眾數填補後進行 One-Hot 編碼，避免整數編碼被誤解為有序數值。14 個類別列展開為 82 個 dummy 變數。   | 中位數填補後標準化，使係數可比較，並使正則化在統一尺度上生效。 | 104  |
| Random Forest        | 眾數填補後保留整數編碼，不進行 One-Hot 展開。                                   | 中位數填補後直接輸入模型，不需要標準化。            | 36   |
| HistGradientBoosting | 眾數填補後使用 OrdinalEncoder，並配合原生 'categorical_features' 參數處理類別分裂。 | 中位數填補後直接輸入模型，不需要標準化。            | 36   |

表 3 不同模型的預處理策略

所有預處理步驟均封裝在 sklearn 的 Pipeline 或 ColumnTransformer 中，確保交叉驗證的每個訓練折獨立完成擬合和轉換，避免驗證集資訊提前進入訓練過程（Pedregosa et al., 2011）。

## 2.5 防洩漏協議

為避免模型使用預測時點之後的資訊，數據處理步驟按照是否依賴目標變數分開執行。標籤無關操作可以在訓練/測試劃分之前完成，例如日期時間解析、-1 轉換為缺失值、車輛表聚合、二值和交互特徵構造、異常值截斷等。這些操作不使用 Accident\_Severity，不會直接造成目標洩漏。

依賴數據分佈或類別標籤的操作則只在訓練集或交叉驗證訓練折內完成，包括缺失值填補參數的擬合、行政區頻率編碼映射的計算、標準化參數的擬合、非對稱欠採樣和模型訓練。測試集只使用訓練集得到的轉換規則，不參與任何參數估計。

非對稱欠採樣尤其需要放在訓練/測試劃分之後。該策略保留全部 Fatal 和 Serious 樣本，並將 Slight 樣本欠採樣至 40%，使訓練集從 1,424,401 行減少到 696,983 行。測試集不進行採樣，仍保持原始類別分佈，以便評估結果反映真實數據條件下的泛化能力。

選擇欠採樣而不是 SMOTE (Chawla et al., 2002)，主要因為原始數據量已經足夠大，欠採樣後仍有約 70 萬條訓練樣本；同時，SMOTE 在混合型特徵空間中可能生成語義不明確的樣本，例如 Is\_Dark=0.6 並不對應任何真實光照條件。

當 Cluster\_ID 作為監督模型的額外特徵時，K-Means 被封裝進 ClusterFeatureTransformer，並嵌入 Pipeline。每個交叉驗證訓練折都會獨立擬合標準化器和 K-Means，驗證折只通過 predict 獲得簇標籤。這樣可以避免驗證折數據參與聚類中心計算，從而控制聚類特徵帶來的洩漏風險。

## 第三章 模型選擇與應用

### 3.1 任務劃分與整體建模思路

正如在 1.2 小節提到的我們本次的研究包含兩個相互關聯的建模任務。第一個是描述任務，目標是在不使用事故嚴重程度標籤的情況下，通過聚類方法觀察事故樣本是否能夠形成若干具有解釋意義的類型。例如，某些事故可能集中表現為城市白天路口碰撞，另一些事故則更接近鄉村高速或惡劣天氣場景。這個任務的重點不是預測，而是幫助理解數據中是否存在穩定的事故模式。

第二個是預測任務，目標是利用事故發生初期可以獲得的道路、環境、時間和車輛資訊，建立監督學習模型，預測 Fatal、Serious 和 Slight 三類事故嚴重程度。與聚類不同，監督分類會使用 Accident\_Severity 作為標籤，並通過測試集指標檢驗模型是否具有泛化能力。

這兩個任務並不是彼此獨立的。聚類結果先用於解釋事故樣本中的典型場景，再通過 Cluster\_ID 的方式加入監督模型，檢驗事故類型劃分是否能夠為嚴重程度預測提供額外資訊。如果 Cluster\_ID 能提升模型表現，說明聚類發現了原始特徵之外的結構；如果提升有限，則說明監督模型已經從原始特徵中學習到了類似的場景差異。後續錯誤分析也會重新利用聚類結果，觀察模型在哪些事故類型中更容易出現漏判。

### 3.2 描述任務：事故類型的聚類分析

#### 3.2.1 聚類目的與特徵設定

在描述任務中，聚類用於從事故樣本中提取具有解釋意義的場景類型。由於該階段不使用 Accident\_Severity，聚類結果主要用於理解事故結構，並為後續 Cluster\_ID 增量檢驗和錯誤分析提供基礎。

聚類特徵選擇時，保留了與事故場景關係較直接的變數，包括限速、事故時段、車輛數量、道路類型，以及黑暗、惡劣天氣、濕滑路面、路口和鄉村道路等二值風險特徵。Latitude 和 Longitude 沒有用於 K-Means 訓練，主要是為了避免聚類結果被地理位置主導。這裏希望識別的是“鄉村高速事故”“城市夜間事故”這類跨地區事故類型，而不是簡單地把樣本劃分為不同城市或行政區。

K-Means 使用歐氏距離度量樣本之間的相似性 (MacQueen, 1967)，因此所有聚類特徵在訓練前均經過標準化處理。若不進行標準化，Speed\_limit 等取值範圍較大的變數會在距離計算中佔據過高權重，而二值風險特徵的作用會被削弱。需要說明的是，K-Means 對混合型數據只是一種近似方法，因為該數據同時包含連續變數、計數變數、低基數編碼類別和二值變數。因此，聚類結果主要作為探索性分析工具，而不是被解釋為唯一真實的事故分組。

#### 3.2.2 最優 K 值選擇

我們使用 Elbow Method 和 Silhouette Score 兩種方法交叉驗證 K 值選擇，在 K=2 至 10 的範圍內搜索。Silhouette Score 用於同時衡量樣本在本簇內的緊密程度和與其他簇的分離程度，是聚類品質評估中的常用指標（Rousseeuw, 1987）。




圖 4 不同 K 值下 K-Means SSE 的變化



圖 5 不同 K 值下 Silhouette Score 的變化

Elbow 圖（圖 4）顯示，SSE 隨 K 增大而平滑下降，沒有出現十分明確的拐點。這說明事故樣本並不存在邊界非常清晰的天然簇，也與混合型特徵空間的特點一致。

Silhouette Score（圖 5）的整體數值不高，大致處於 0.21 至 0.25 之間，說明不同簇之間有一定重疊。K=3 時 Silhouette Score 為 0.228，K=9 時達到最高的 0.249，而 K=4 為 0.214。雖然 K=4 不是數值最高的方案，但它能夠形成四類較清楚的事務場景，並且這些場景在嚴重程度分佈上具有明顯差異。相比之下，K=3 會把城市白天事故和城市夜間事故合併，削弱光照條件的解釋作用；K=5 新增的簇主要由單行道特徵區分，風險解釋不夠明確。因此，我們最終採用 K=4 作為聚類方案。




圖 6 K=4 聚類結果的 PCA 二維投影

圖 6 通過 PCA 將 K=4 聚類結果投影到二維空間。前兩個主成分共解釋約 40.1% 的方差，因此該圖主要用於輔助觀察聚類結構。從圖中可以看到，不同簇具有一定分佈差異，但仍存在明顯重疊，這與 Silhouette Score 偏低的結果一致。由此可見，聚類結果可以幫助概括事故類型，但不應被解釋為邊界清晰的

真實類別。

### 3.2.3 簇特徵畫像與嚴重程度關聯

K=4 的聚類結果可以概括為四類事故場景。各簇並不是按照嚴重程度生成的，但它們與嚴重程度分佈之間存在明顯聯繫。

| 簇編號       | 樣本占比  | 事故類型概括   | 主要特徵                                                     | 嚴重程度特點                      |
|-----------|-------|----------|----------------------------------------------------------|-----------------------------|
| Cluster 0 | 44.4% | 城市白天路口事故 | 平均限速 30.9 mph, 'At_Junction' 為 72.3%, 'Is_Rural' 僅 7.0%  | Fatal 率 1.32%, 四類中最低        |
| Cluster 1 | 18.0% | 惡劣天氣事故   | 'Bad_Weather' 為 99.9%, 'Wet_Road' 為 93.9%, 平均限速 41.1 mph | Fatal 率 2.36%, 高於城市白天簇      |
| Cluster 2 | 12.4% | 城市夜間事故   | 'Is_Dark' 為 100%, 平均事故小時約為 19.4, 'At_Junction' 為 68.3%   | Fatal 率 2.46%, 與惡劣天氣簇接近     |
| Cluster 3 | 25.2% | 鄉村高速事故   | 平均限速 56.7 mph, 'Is_Rural' 為 96.3%, 'At_Junction' 僅 32.0% | Fatal 率 5.25%, 約為城市白天簇的 4 倍 |

表 4 K=4 聚類結果及事故類型解釋

從結果看，城市白天路口事故數量最多，但致命事故比例最低；鄉村高速事故數量並非最多，卻具有最高的 Fatal 率。這一差異說明，限速和道路環境對事故後果具有較強影響。惡劣天氣和夜間條件會增加風險，但它們在本數據中不如鄉村高速場景那樣顯著提高 Fatal 比例。

圖 7 展示了四類簇的特徵畫像，圖 8 進一步給出了不同簇與事故嚴重程度之間的對應關係。二者共同說明，聚類雖然不能直接替代監督模型，但能夠幫助解釋事故樣本中存在的典型風險場景。




圖 7 K=4 聚類中心的標準化特徵畫像




圖 8 四類事故原型與事故嚴重程度的交叉分佈

### 3.2.4 層次聚類對比

為避免聚類結論完全依賴 K-Means，我們又使層次聚類（Agglomerative Clustering）進行對比。該方法採用 Ward linkage，自底向上合併樣本，並儘量使合併後簇內平方誤差增加最小。由於層次聚類需要計算距離矩陣，直接在完整數據集上運行會佔用過高記憶體，因此實驗在子樣本上進行，用 20,000 條樣本用於聚類比較，5,000 條樣本用於繪製 dendrogram（如圖 9）。




圖 9 層次聚類的層次結構示意圖

在  $K=4$  時，K-Means 與 Agglomerative Clustering 的 Adjusted Rand Index 為 0.382（Hubert & Arabie, 1985），說明兩種方法得到的分組具有中等一致性。這個結果表明，前述四類事故模式並不是 K-Means 獨有的偶然結果，但不同演算法之間也沒有完全一致，說明事故數據本身的簇邊界較為模糊。這樣的結果與前面較低的 Silhouette Score 相互印證。

### 3.2.5 Cluster\_ID 融合設計與防洩漏

為檢驗聚類結構是否能夠為監督預測提供額外資訊，Cluster\_ID 被作為衍生特徵加入分類模型。為避免資訊洩漏，ClusterFeatureTransformer 被嵌入 sklearn Pipeline，並放在 ColumnTransformer 之前。它只使用與前述 K-Means 聚類相同的 9 個特徵，在每個訓練折內部完成標準化和 K-Means 擬合，再將生成的



Cluster\_ID 追加到數據中。驗證集和測試集只根據訓練折得到的聚類中心分配簇標籤，不參與聚類中心計算。

這種設計還有一個好處是監督模型中的 Cluster\_ID 與前文 EDA 中解釋過的四類事故原型保持一致。若先經過 One-Hot 編碼或其他預處理後再聚類，簇標籤會來自新的高維特徵空間，可能不再對應“城市白天路口事故”“鄉村高速事故”等已解釋的事故類型，削弱後續增量分析的可解釋性。

實驗結果顯示，加入 Cluster\_ID 後各模型的 Macro F1 變化均在  $\pm 0.002$  以內，說明原始監督特徵已經基本包含了聚類所表達的結構資訊。相關結果將在 4.6 節進一步分析。

### 3.3 預測任務：事故嚴重程度分類的監督學習

#### 3.3.1 模型選擇

監督學習部分的目標是預測 Accident\_Severity，即將事故劃分為 Fatal、Serious 和 Slight 三類。考慮到數據存在極端類別不平衡，模型比較不能只依賴 Accuracy，而需要同時關注 Macro F1、Balanced Accuracy、Fatal Recall 和 Precision 等指標。

模型選擇上，我們使用 Logistic Regression、Random Forest 和 HistGradientBoosting 三種方法。三者的複雜度和學習機制不同，能夠從不同角度檢驗事故嚴重程度分類問題。Logistic Regression 用於建立線性基線，Random Forest 用於捕捉非線性關係並降低單棵樹的不穩定性，HistGradientBoosting 則通過 Boosting 逐步修正前一輪模型的錯誤，更適合觀察模型對少數類樣本的回應。

| 模型                   | 選擇理由                | 主要作用                      |
|----------------------|---------------------|---------------------------|
| Logistic Regression  | 結構簡單、可解釋性強，適合作為線性基線 | 判斷主效應特徵是否已經能解釋主要分類差異      |
| Random Forest        | 能處理非線性關係，並提供特徵重要性   | 檢驗 Bagging 集成模型在不平衡數據上的表現 |
| HistGradientBoosting | 訓練效率較高，支持類別特徵和類別權重  | 檢驗 Boosting 模型對少數類的識別能力   |

表 5 監督學習模型選擇理由

#### 3.3.2 邏輯回歸 (Logistic Regression)

Logistic Regression 用於提供一個穩定的線性參照。經過 One-Hot 編碼和標準化後，模型可以直接學習各個特徵對不同嚴重程度類別的影響方向和強度。由於類別極不平衡，訓練時使用 `class_weight='balanced'`，使 Fatal 和 Serious 樣本在損失函數中獲得更高權重。

該模型的意義不只在於提供基線結果。如果 Logistic Regression 的性能接近甚至超過非線性模型，說明事故嚴重程度在很大程度上可以由限速、道路環境、光照和天氣等特徵的主效應解釋；如果非線性模型明顯更好，則說明複雜交互關



係可能更重要。最終結果中，Logistic Regression 在測試集上的 Macro F1 為 0.400，Fatal Recall 為 0.318，Balanced Accuracy 為 0.463，整體表現較為均衡。具體指標比較在第四章有展開。

### 3.3.3 隨機森林 (Random Forest)

Random Forest 通過多棵決策樹的集成進行預測。每棵樹在 bootstrap 樣本和隨機特徵子集上訓練，最終通過多數投票得到分類結果。相比單棵樹，Random Forest 能減少過擬合風險，也能捕捉特徵之間的非線性關係 (Breiman, 2001)。

在初始參數下，Random Forest 的總體 Accuracy 較高，但 Fatal Recall 很低，說明模型仍明顯偏向多數類 Slight。後續 GridSearchCV 對樹深和葉節點最小樣本數進行了調節，其中 max\_depth 從不限制改為 20，min\_samples\_leaf 從 1 調整為 4。正則化後，模型對 Fatal 類的識別明顯改善，測試集 Fatal Recall 從 0.005 提升至 0.222，Macro F1 達到 0.397。

這一結果說明，Random Forest 在不平衡數據上並非完全無效，但默認參數容易使樹模型過度擬合多數類結構。適當限制樹深和葉節點規模後，class\_weight 的作用才能更充分體現。不過，即使經過調優，Random Forest 對 Fatal 類的識別仍弱於 HistGradientBoosting 和 Logistic Regression，說明多數投票機制在極端不平衡任務中仍有一定局限。

### 3.3.4 直方圖梯度提升 (HistGradientBoosting)

HistGradientBoosting 屬於 Boosting 模型，通過逐輪訓練新樹來修正前一輪模型的錯誤。與傳統 Gradient Boosting 相比，HistGradientBoosting 使用直方圖分裂，訓練效率更適合大規模數據；同時，它能夠配合類別特徵處理和類別權重設置，適合用於本項目的百萬級事故數據 (Friedman, 2001)。

從結果看，HistGradientBoosting 對 Fatal 類最敏感。在 Scheme C 設置下，其 Fatal Recall 達到 0.652，明顯高於 Logistic Regression 和 Random Forest。但這一優勢伴隨較低的 Fatal Precision，僅為 0.044，意味著模型會將大量非 Fatal 事故誤判為 Fatal。換言之，它更適合“不希望漏掉致命事故”的場景，但會帶來較高誤報成本。

這種表現與 Boosting 的訓練機制有關。模型在迭代過程中會持續關注前一輪難以分類的樣本，而 Fatal 類樣本在類別權重和採樣策略的共同作用下被進一步放大。因此，HistGradientBoosting 能顯著提高 Fatal Recall，但也更容易出現過度糾偏。第四章的不平衡處理分析將進一步討論這一現象。

### 3.3.5 三類模型的差異

三個模型在同一任務上的表現並不只是“誰的分數更高”的問題。Logistic Regression 的優勢在於穩定和可解釋，最終取得最高的 Macro F1；Random Forest 在正則化後表現接近 Logistic Regression，但對 Fatal 類仍偏保守；HistGradientBoosting 的 Fatal Recall 最高，但 Precision 明顯偏低。

這說明模型選擇應結合使用場景判斷。如果目標是整體三分類性能，Logistic Regression 更合適；如果目標是盡可能減少 Fatal 漏判，HistGradientBoosting 更

有吸引力；如果需要非線性建模和特徵重要性分析，Random Forest 仍有參考價值。由於不同模型在少數類識別和誤報控制之間存在差異，後續評估不再只比較 Accuracy，而是同時分析多項指標。

### 3.3.6 不平衡處理的消融設計

在建立模型後，為了避免模型被多數類 Slight 主導，還需要單獨考察類別不平衡處理方式的影響。我們設計了三組消融方案，用於區分演算法級加權和數據級採樣各自的作用。具體設置見表 6，比較結果將在第四章通過交叉驗證給出。

| 方案       | 數據級<br>重平衡 | 演算法<br>級重加<br>權 | Fatal 樣<br>本 | Serious<br>樣本 | Slight 樣<br>本 | 實驗目的                                            |
|----------|------------|-----------------|--------------|---------------|---------------|-------------------------------------------------|
| Scheme A | —          | ✓               | 100%         | 100%          | 100%          | 僅使用<br>'class_weight='balanced'，<br>檢驗類別權重本身的作用 |
| Scheme B | ✓          | —               | 100%         | 100%          | 40%           | 僅使用非對稱欠採樣，檢<br>驗訓練集分佈調整的作用                      |
| Scheme C | ✓          | ✓               | 100%         | 100%          | 40%           | 同時使用欠採樣與類別權<br>重，檢驗二者是否具有互<br>補效果               |

表 6 消融實驗設計

## 第四章 評估與結果分析

### 4.1 評估設計與指標選擇

前文已經明確，本研究的核心問題不是簡單地追求一個較高的分類準確率，而是在只使用事故初期可獲得資訊的條件下，判斷機器學習模型是否能夠有效區分 Fatal、Serious 和 Slight 三類事故嚴重程度。圍繞這一問題，我們的實驗評估需要回答三件事，第一，模型在真實類別分佈下是否具有可用的三分類能力；第二，哪些環境、車輛和時間因素在不同模型中穩定地關聯嚴重事故；第三，聚類得到的事故類型是否能為監督預測提供額外資訊。

由於數據集存在明顯的類別不平衡，評估指標的選擇會直接影響結論。Slight 類約占全部樣本的 85%，而 Fatal 類僅占約 1.3%。如果只看 Accuracy，一個主要預測多數類的模型也可能得到較高分數，但這並不能說明模型真正識別了高嚴重度事故。因此 Accuracy 在只作為輔助指標使用，主要結論不以它單獨決定。

綜合指標採用 Macro F1。該指標對三個類別賦予相同權重，能夠避免多數類在評價中佔據過大影響，更適合衡量模型對 Fatal 和 Serious 的識別能力。同時，實驗使用 Balanced Accuracy、Fatal Recall 和 Serious Recall。Balanced Accuracy 用於衡量各類別召回率的平均水準；Fatal Recall 關注致命事故是否被漏判；Serious Recall 則用於觀察模型對中間嚴重度事故的識別能力。Precision-Recall 曲線也被納入分析，因為在少數類比例很低時，PR 曲線比 ROC 曲線更能反映模型識別少數類的實際品質（Saito & Rehmsmeier, 2015）。

我們將評估流程分為三個層次，第一層是在訓練集內部進行模型選擇（**5-fold stratified cross-validation**），用於選擇不平衡處理方案和超參數配置。第二層是在預留測試集上進行**最終模型比較（Held-out Test Set）**，測試集保持原始類別分佈，不參與模型選擇。第三層是**時間 holdout 實驗**，即使用 2005—2012 年數據訓練、2013—2015 年數據測試，用於檢查模型是否能適應時間分佈變化。這樣的順序可以避免測試集被反復用於調參，也使評估邏輯更清楚：先在訓練集內部確定建模方案，再用未參與選擇的數據回答模型是否真正有效。

### 4.2 不平衡處理方案的消融實驗

在比較最終模型之前，必須先解決訓練階段的類別不平衡問題。若不進行處理，模型容易優先學習多數類 Slight 的模式，從而忽略 Fatal 這類少數但更重要的事故。第三章已經設置了三種方案，Scheme A 只使用 `class_weight='balanced'`，Scheme B 只進行非對稱欠採樣，Scheme C 同時使用欠採樣和 `class_weight='balanced'`。我們在訓練集內部通過 5-fold stratified cross-validation 比較這三種方案，評價指標為 Macro F1。

| 方案       | Undersampling | Class Weight | LR    | HistGBT | RF    | Avg.  |
|----------|---------------|--------------|-------|---------|-------|-------|
| Scheme A | —             | ✓            | 0.379 | 0.357   | 0.336 | 0.357 |
| Scheme B | ✓             | —            | 0.344 | 0.365   | 0.358 | 0.356 |
| Scheme C | ✓             | ✓            | 0.420 | 0.408   | 0.374 | 0.401 |

表 7 類別不平衡處理消融結果（5-fold CV Macro F1）




圖 10 三種不平衡處理方案的 Macro F1 對比

表 7 與第三章的消融設置一一對應。結果顯示，Scheme A 和 Scheme B 的平均 Macro F1 接近，分別為 0.357 和 0.356，說明單獨使用類別權重或單獨欠採樣都不足以穩定改善整體表現。Scheme C 同時引入數據級重平衡和演算法級重加權，三個模型的 Macro F1 均達到最高，平均值提升至 0.401。圖 10 進一步展示了這一趨勢，三類模型在 Scheme C 下均高於另外兩種方案，說明提升不是某一個模型的偶然結果。

僅使用欠採樣的 Scheme B 在 Fatal 類上表現尤其弱。雖然欠採樣減少了多數類樣本，但 Fatal 類本身仍然非常稀少，模型很難只依靠樣本比例變化學習到穩定的致命事故特徵。圖 11 從 Fatal Recall 的角度更直觀地顯示了這一點：僅欠採樣時，三個模型對 Fatal 類的召回率都接近零。這說明在極端少數類問題中，演算法級類別權重仍然是必要的。




圖 11 不平衡處理方案下 Fatal Recall 的熱力圖

不過，Scheme C 也引入了新的取舍。以 HistGradientBoosting 為例，雙重重平衡使模型對 Fatal 類更加敏感，Fatal Recall 明顯提高，但 Fatal Precision 下降到 0.044。這意味著模型減少了致命事故漏判，但同時會把更多非致命事故誤報為致命事故。圖 12 展示了這種 Recall 與 Precision 之間的權衡關係：少數類召回率的提升並不是無成本的，尤其是在 Fatal 類樣本占比極低的情況下。




圖 12 不平衡處理方案下 Fatal Recall 與 Precision 的權衡

交叉驗證結果還需要關注穩定性。圖 13 展示了不同不平衡處理方案在各折中的表現分佈。Scheme C 雖然整體最好，但不同模型的波動程度並不完全相同，這說明後續仍需要在獨立測試集上進一步確認最終性能。綜合 Macro F1、Fatal Recall 和穩定性，後續實驗採用 Scheme C 作為主要訓練方案。




圖 13 不平衡處理方案的跨折穩定性對比

### 4.3 超參數調優結果

確定 Scheme C 作為主要不平衡處理方案後，下一步是在訓練集內部確定各模型的參數配置。調優採用 GridSearchCV，仍使用 5-fold stratified cross-validation，並以 Macro F1 作為優化目標。這樣可以保證測試集只用於最終評估，而不參與訓練策略或參數選擇。

| 模型                   | 調優前 CV Macro F1 | 調優後 CV Macro F1 | 變化     |
|----------------------|-----------------|-----------------|--------|
| Logistic Regression  | 0.421           | 0.421           | 0.000  |
| HistGradientBoosting | 0.408           | 0.408           | 0.000  |
| Random Forest        | 0.374           | 0.448           | +0.074 |

表 8 超參數調優前後的 CV Macro F1 變化

表 8 顯示，Logistic Regression 和 HistGradientBoosting 在當前搜索空間內幾乎沒有提升，說明二者對所設定的超參數範圍不敏感，原始參數已經接近較優區域。圖 14 中兩類模型的 CV 分佈也較集中，進一步說明其性能變化有限。

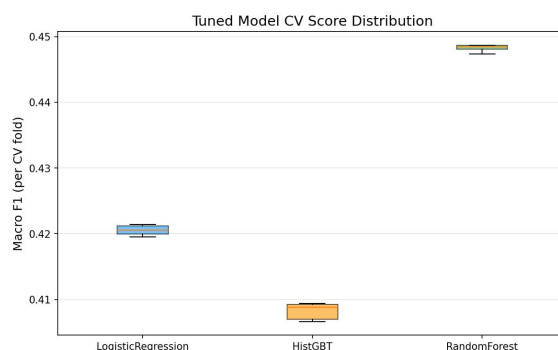


圖 14 調優後 CV Macro F1 的跨折分佈

相比之下，Random Forest 對參數設置非常敏感。調優後，max\_depth 被限制為 20，min\_samples\_leaf 提高到 4，模型複雜度受到約束，CV Macro F1 從 0.374 提升到 0.448。圖 15 中 Random Forest 的參數敏感性更加明顯，說明樹深和葉節點規模會顯著影響它在不平衡數據上的表現。




圖 15 三類模型的超參數敏感度曲線

這一變化也解釋了 Random Forest 初始結果較差的原因。默認參數下，樹模型容易學習多數類中的局部結構，即使設置類別權重，多數投票仍可能把邊界樣本判回 Slight。限制樹深和葉節點規模後，模型對少數類的識別有所改善，測試集 Fatal Recall 從 0.005 提升至 0.222。圖 16 對比了調優前後的結果，可以看到主要性能提升集中在 Random Forest 上。因此，後續最終測試中 Random Forest 均採用調優後的配置。




圖 16 Random Forest 超參數調優前後的性能對比

## 4.4 測試集上的最終模型比較

經過不平衡處理方案和超參數配置的選擇後，可以在預留測試集上回答核心問題：僅依靠事故初期可獲得的資訊，模型能否有效區分三類事故嚴重程度。測試集保持原始類別分佈，因此該結果比訓練集交叉驗證更接近真實應用條件下的泛化表現。

| 模型                   | Accuracy | Balanced Accuracy | Macro F1 | Fatal Recall | Serious Recall |
|----------------------|----------|-------------------|----------|--------------|----------------|
| Logistic Regression  | 0.744    | 0.463             | 0.400    | 0.318        | 0.240          |
| Random Forest (調優後)  | 0.650    | 0.476             | 0.397    | 0.222        | 0.532          |
| HistGradientBoosting | 0.562    | 0.548             | 0.358    | 0.652        | 0.406          |

表 9 三類模型在測試集上的性能比較

測試結果表明，模型具有一定的事故嚴重程度區分能力，但三類模型的優勢不同。圖 17 將 Accuracy、Balanced Accuracy、Macro F1 和各類 Recall 放在一起比較，可以看到不存在絕對意義上的單一最優模型。Logistic Regression 的 Macro F1 最高，為 0.400，說明它在三類整體均衡表現上最穩定。雖然它是線性模型，但限速、城鄉環境、光照、天氣和車輛聚合特徵已經提供了較強的主效應信號，因此複雜模型並沒有在綜合指標上形成明顯優勢。




圖 17 三類模型的測試集性能對比

混淆矩陣能進一步說明模型差異。圖 18 中，Random Forest 對 Serious 類的識別最強，Serious Recall 達到 0.532，但對 Fatal 類仍偏保守，Fatal Recall 只有 0.222。這說明 Bagging 多數投票機制在中間嚴重度事故上較有效，但在極端少數類識別上仍受到限制。




圖 18 三類模型的混淆矩陣

HistGradientBoosting 的表現最偏向高嚴重度識別。它的 Fatal Recall 達到 0.652，明顯高於其他兩個模型，但 Accuracy 和 Macro F1 相對較低。說明模型更願意將樣本判為高嚴重度事故，從而減少 Fatal 漏判，但同時會產生更多誤報。圖 19 的 Precision-Recall 曲線也反映了這一點，Fatal 類召回率較高的同時，Precision 受到明顯壓低。




圖 19 三類模型的 Precision-Recall 曲線對比

ROC 曲線見圖 20。由於 ROC 在類別極不平衡時可能顯得過於樂觀，因此這裏只將其作為輔助觀察。相比之下，PR 曲線、Recall 和 Precision 更能反映 Fatal 類識別的實際困難。綜合來看，如果應用目標是盡量避免漏掉致命事故，HistGradientBoosting 具有參考價值；如果目標是整體三分類更均衡，Logistic Regression 更合適；如果關注 Serious 類識別，調優後的 Random Forest 更有優勢。




圖 20 三類模型的 ROC 曲線對比



## 4.5 穩定風險因素與特徵解釋

在確認模型具有一定預測能力後，還需要進一步回答第二個研究問題：哪些環境、車輛和時間因素與嚴重事故的關係更穩定。為此，結合 Random Forest 和 HistGradientBoosting 的特徵重要性、Logistic Regression 的係數，以及跨模型特徵重要性對比，觀察不同模型是否關注相似變數。

圖 21 展示了 Random Forest 的特徵重要性。結果顯示，模型較多依賴車輛聚合特徵、地區頻率編碼、時間變數以及限速等資訊，其中 Mean\_Engine\_Capacity、Mean\_Driver\_Age、LA\_Frequency、Mean\_Vehicle\_Age、Number\_of\_Vehicles 和 Speed\_limit 等變數的重要性較高。這說明事故嚴重程度的預測並不是由單一道路條件決定，而是與車輛屬性、地理分佈、時間因素和速度條件共同相關。

Logistic Regression 的係數幅度結果見圖 22。該圖從線性模型角度展示了哪些特徵對分類邊界影響較大。與 Random Forest 不同，Logistic Regression 更突出道路危險條件、路口資訊、道路等級、時段和車輛類型等變數。兩類模型關注的重點並不完全相同，但都指向同一結論，事故嚴重程度與道路環境、車輛結構、時間條件和速度相關因素共同作用有關，而不是由某一單一變數決定。




圖 21 Random Forest 的特徵重要性




圖 22 Logistic Regression 的主要係數幅度




圖 23 RF 與 HistGBT 的跨模型特徵重要性對比

圖 23 進一步匯總了跨模型特徵重要性。與第三章的聚類結果對照可以發現，鄉村高速事故在聚類中具有最高 *Fatal* 率，監督模型中與速度和鄉村道路相關的變數也具有較高重要性。黑暗、濕滑路面和惡劣天氣等變數雖然不一定單獨決定事故嚴重程度，但它們與速度和道路環境共同出現時，會明顯改變事故後果。

但是要強調的是特徵重要性反映的是模型內部的預測依賴關係，而不是嚴格的因果關係。例如，鄉村道路與 *Fatal* 風險較高相關，並不意味著鄉村道路本身必然導致致命事故；它可能同時伴隨更高限速、更少照明、更遠救援距離等因素。因此，這些特徵更適合作為風險識別線索，而不能直接解釋為單一因果機制。

## 4.6 Cluster\_ID 的增量資訊檢驗

除了直接分析特徵，還需要回答第三個研究問題：事故樣本是否能夠形成具有解釋意義的分群，並且這些分群是否能補充監督模型的預測資訊。前面已經通過 *K-Means* 得到四類事故原型，實驗進一步將 *Cluster\_ID* 作為額外特徵加入監督模型，檢驗聚類結構是否能提供增量資訊。

為了避免資訊洩漏，*Cluster\_ID* 在 *Pipeline* 內部生成。訓練折內部擬合標準化器和 *K-Means*，驗證集和測試集只根據訓練折得到的聚類中心分配簇標籤，不參與聚類中心計算。因此，*Cluster\_ID* 的評估結果不會因為提前接觸驗證集或測試集而被高估。

實驗結果顯示，加入 *Cluster\_ID* 後，三個模型的 *Macro F1* 變化均在  $\pm 0.002$  以內，幾乎沒有穩定增益。這說明原有 36 個監督特徵已經較充分地包含了聚類所表達的結構資訊。分類模型直接使用限速、道路環境、光照、天氣和車輛聚合特徵時，已經能夠組合出類似“城市白天路口事故”“鄉村高速事故”等模式，因此額外加入簇編號並不會顯著改善預測性能。這個結果並不否定聚類的作用。聚類的價值主要在於解釋事故類型，而不是提高分類分數。四類事故原型的 *Fatal* 率從 1.32% 到 5.25% 不等，說明不同場景的風險水準確實存在差異。後續錯誤分析仍會利用這些事故原型，觀察模型在哪些場景下最容易出現漏判。

## 4.7 時間分佈漂移下的魯棒性

測試集評估採用隨機劃分，能夠反映一般泛化能力，但無法完全檢驗模型在不同年份下是否穩定。為進一步判斷模型是否只是適應了某一時期的數據分佈，進行時間 *holdout* 實驗。我們使用 2005—2012 年數據訓練，2013—2015 年數據測試。

| 模型                   | CV (L1) | Test (L2) | Temporal (L3) | CV $\rightarrow$ Test | Test $\rightarrow$ Temporal |
|----------------------|---------|-----------|---------------|-----------------------|-----------------------------|
| Random Forest        | 0.448   | 0.397     | 0.396         | -0.051                | -0.001                      |
| HistGradientBoosting | 0.408   | 0.358     | 0.353         | -0.050                | -0.005                      |
| Logistic Regression  | 0.421   | 0.400     | 0.408         | -0.020                | +0.008                      |

表 10 三層評估下的 *Macro F1* 對比

從 Macro F1 看，測試集和時間 holdout 的結果非常接近。Random Forest 只下降 0.001，HistGradientBoosting 下降 0.005，Logistic Regression 反而上升 0.008。圖 24 中 Macro F1 的變化也較平穩，說明事故嚴重程度的整體分類模式在時間上較為穩定，限速、道路環境、光照和天氣等因素在不同年份中仍具有相似的預測作用。




圖 24 L1、L2 與 L3 三層評估結果對比

但圖 24 同時顯示，Fatal Recall 的下降比 Macro F1 更明顯。Random Forest 從 0.222 降至 0.169，HistGradientBoosting 從 0.652 降至 0.591，Logistic Regression 從 0.318 降至 0.208。也就是說，模型對整體三分類結構較穩定，但對最少數的 Fatal 類更敏感。後期 Fatal 事故可能具有與早期不同的特徵組合，而 STATS19 中缺少碰撞速度、碰撞角度、安全帶使用和車輛安全系統等更直接的嚴重程度決定因素，因此 Fatal 類識別在時間遷移中下降更明顯。

整體來看，模型沒有出現嚴重的時間失效，但 Fatal 類的下降提示，實際使用中不能只監控整體指標，還需要持續檢查少數類表現。

## 4.8 聚類視角下的錯誤分析

前面的結果表明，Cluster\_ID 作為額外特徵並沒有明顯提高模型分數，但聚類結果仍然可以用於解釋模型錯誤。為了進一步觀察模型在哪些事故場景下更容易失誤，本節以調優後的 Random Forest 為例，將測試集預測結果與 K=4 聚類結果進行交叉分析。這樣可以把監督模型的誤分類模式與第三章得到的四類事故原型聯繫起來。

圖 25 展示了不同事故簇中各真實類別的誤分類率。這裏的列表表示真實類別，顏色和數值表示該真實類別在對應簇中被預測錯誤的比例。例如，Fatal 列表示真實 Fatal 事故被誤判為非 Fatal 的比例，因此它可以反映每個簇中 Fatal 識別的困難程度。整體來看，Random Forest 對 Fatal 類的誤分類率明顯高於 Serious 和 Slight，說明致命事故仍然是最難識別的類別。




圖 25 L1、L2 與 L3 三層評估結果對比

從圖 25 可以看出，Cluster 3 的 Fatal 誤分類率最低，為 0.616，對應 Fatal Recall 為 38.4%。該簇主要對應鄉村高速事故，具有較高限速和明顯的鄉村道路特徵，因此模型更容易識別其中的高風險樣本。相反，Cluster 0 和 Cluster 2 的 Fatal 誤分類率分別達到 0.989 和 0.972，對應 Fatal Recall 僅為 1.1% 和 2.8%，說明城市白天路口和城市夜間事故中的 Fatal 樣本在現有特徵空間中不夠突出。圖 25 只能反映總體誤分類率，不能區分 Fatal 被誤判為 Serious 還是 Slight。為進一步觀察更嚴重的低估情況，表 11 統計了各簇的 Fatal Recall，以及真實 Fatal 被直接誤判為 Slight 的比例。

| 簇 | 原型     | Fatal Recall | 真實 Fatal 被誤判為 Slight 的比例 |
|---|--------|--------------|--------------------------|
| 0 | 城市白天路口 | 1.1%         | 37.8%                    |
| 1 | 惡劣天氣   | 16.4%        | <b>40.6%</b>             |
| 2 | 城市夜間   | 2.8%         | 31.5%                    |
| 3 | 鄉村高速   | <b>38.4%</b> | 20.7%                    |

表 11 調優後 Random Forest 在不同事故簇中的 Fatal 識別與嚴重漏判情況

表 11 顯示，Cluster 1 即惡劣天氣事故中，真實 Fatal 被直接誤判為 Slight 的比例最高，達到 40.6%。這說明惡劣天氣場景存在明顯的嚴重程度低估風險。可能原因是，同樣處於惡劣天氣或濕滑路面條件下，大量事故仍屬於 Slight 或 Serious；真正決定 Fatal 後果的因素可能是碰撞強度、碰撞角度或人員保護情況，而這些變數並未包含在當前數據集中。

聚類雖然沒有提升 Macro F1，但能幫助定位模型薄弱場景。鄉村高速事故中的 Fatal 相對更容易識別，而城市低速路口、城市夜間和惡劣天氣場景中的 Fatal 更容易被低估。

## 第五章 總結與未來展望

### 5.1 研究結論

我們小組圍繞事故初期資訊能否支持嚴重程度預測這一問題，基於英國 STATS19 道路交通事故數據集，完成了從數據清洗、特徵工程、聚類分析到監督分類評估的完整機器學習流程。實驗只使用事故發生初期相對可獲得的道路、環境、時間和車輛資訊，排除了傷亡表以及其他可能包含事後結果的資訊，從而避免模型通過結果變數反推事故嚴重程度。

從最終測試結果看，僅依靠這些初期資訊，模型能夠對 Fatal、Serious 和 Slight 三類事故形成一定區分，但識別能力仍然有限。Logistic Regression 在整體三分類表現上最穩定，測試集 Macro F1 達到 0.400；HistGradientBoosting 對 Fatal 類最敏感，Fatal Recall 達到 0.652，但同時帶來較高誤報；調優後的 Random Forest 對 Serious 類識別更好，Serious Recall 達到 0.532。由此可見，不同模型並不存在絕對意義上的最優選擇，模型價值取決於具體應用目標：若追求整體均衡，Logistic Regression 更合適；若希望儘量減少致命事故漏判，HistGradientBoosting 更有參考意義；若關注中間嚴重度事故，Random Forest 的表現更突出。

類別不平衡是影響模型表現的關鍵因素。消融實驗表明，單獨使用欠採樣或單獨使用類別權重都難以穩定改善結果，尤其無法有效識別極少數的 Fatal 類。非對稱欠採樣與 `class_weight='balanced'` 結合後，三個模型的 Macro F1 均達到各自最高水準，說明數據級重平衡和演算法級重加權在本任務中具有互補作用。不過，這種處理也會帶來 Recall 與 Precision 之間的取捨，尤其在 HistGradientBoosting 中表現明顯：模型能識別更多 Fatal 事故，但也會把更多非 Fatal 事故誤判為 Fatal。

特徵分析顯示，事故嚴重程度並不是由單一變數決定，而是與道路環境、速度條件、時間因素和車輛結構共同相關。限速、城鄉區域、道路類型、路口資訊、光照條件以及車輛聚合特徵在不同模型和解釋方式中反復出現，說明這些變數與嚴重事故具有較穩定的預測關聯。這也解釋了為什麼 Logistic Regression 作為線性模型仍能取得較好的 Macro F1，也就是在當前特徵空間中，若干主效應特徵已經包含了相當多的可用資訊，複雜非線性模型並沒有在整體綜合指標上形成明顯優勢。

聚類分析進一步提供了對事故類型的解釋。K-Means 將事故樣本概括為城市白天路口、惡劣天氣、城市夜間和鄉村高速四類原型，其中鄉村高速簇具有最高 Fatal 率。將 Cluster\_ID 加入監督模型後，Macro F1 幾乎沒有提升，說明原始監督特徵已經基本包含了聚類所表達的結構資訊。但聚類並非沒有價值。按簇分析錯誤模式後可以看到，城市低速路口、城市夜間和惡劣天氣場景中的 Fatal 事故更容易被低估，尤其惡劣天氣簇中真實 Fatal 被直接誤判為 Slight 的比例較高。這說明聚類更適合作為解釋和錯誤歸因工具，而不是單純作為提升預測分

數的輸入特徵。

時間 holdout 實驗顯示，模型整體 Macro F1 在 2013—2015 年數據上保持相對穩定，說明道路環境、速度和光照等因素對事故嚴重程度的預測關係具有一定時間穩定性。但 Fatal Recall 在時間遷移中下降更明顯，表明最少數類對時間分佈變化更加敏感。也可以看到，事故初報信息可以支持一定程度的嚴重程度預判，但現有特徵仍不足以穩定識別所有致命事故。

## 5.2 研究局限

此次研究的主要局限來自數據本身。STATS19 是警方事後整理的結構化事故記錄，並不是真正的即時調度數據。雖然實驗中儘量只保留事故初期可能獲得的資訊，但這些字段在真實報案場景中是否能夠即時、準確地獲取，仍需要進一步驗證。因此我們認為使用該數據集更適合作為嚴重程度預測的可行性分析，而不是可直接部署的即時系統。

同時特徵空間也存在明顯缺口。事故最終是否發展為 Fatal，往往與實際碰撞速度、碰撞角度、車輛安全保護、乘客年齡與健康狀況、安全帶使用情況、氣囊觸發情況和救援回應時間等因素有關。這些變數在當前數據集中缺失或不適合作為事故初期特徵使用，使模型很難區分某些特徵表面相似但後果差異很大的事故。城市白天路口和惡劣天氣場景中的 Fatal 漏判，正反映了這種限制。

類別不平衡仍然也是模型訓練中的核心困難，儘管雙重重平衡策略提高了 Macro F1 和 Fatal Recall，但少數類樣本數量過少的問題並沒有從根本上消失。提高 Recall 往往會犧牲 Precision，降低誤報又可能增加漏判。對於致命事故這種極少數但高代價類別，模型評估不能只停留在單一分數上，還需要結合實際應用中的誤報成本和漏報成本進行判斷。

聚類方法也有一定限制，K-Means 使用歐氏距離和球形簇假設，而本研究的聚類特徵同時包含連續變數、計數變數、二值變數和低基數類別變數，因此聚類結果只能作為探索性解釋。較低的 Silhouette Score 也說明事故樣本並不存在邊界非常清楚的天然分組。四類事故原型具有解釋價值，但不應被理解為客觀存在且嚴格分離的事故類型。

## 5.3 未來工作

後續研究可以從數據擴展入手。若能引入更接近事故後果形成機制的變數，例如實際碰撞速度、碰撞角度、道路幾何結構、交通流量、車輛安全配置、乘員保護資訊和救援回應時間，模型對 Fatal 類的識別可能會更加穩定。對於惡劣天氣和城市路口這類容易被低估的場景，補充碰撞強度和人員保護相關資訊尤其重要。

在模型方法上，可以進一步嘗試更適合有序標籤和極端不平衡問題的演算法。Fatal、Serious 和 Slight 並不是完全無序的類別，而是具有嚴重程度遞進關係，因此有序分類模型可能比普通多分類模型更符合任務結構。同時，focal loss、

代價敏感學習或針對少數類的閾值調整 (Lin et al., 2017)，也可以用於緩解 Fatal 類 Recall 與 Precision 之間的矛盾。

模型解釋方面，還可以在特徵重要性之外加入樣本級解釋方法。當前分析主要說明哪些變數整體上重要，但還不能回答某一具體事故為什麼被判為 Fatal 或為什麼被誤判為 Slight。若結合 SHAP 等方法 (Lundberg & Lee, 2017)，可以進一步分析單個樣本的預測依據，特別是模型在惡劣天氣和城市低速路口場景中低估 Fatal 風險的具體原因。

時間泛化也值得繼續檢查。我們實驗的時間 holdout 只採用 2005—2012 年訓練、2013—2015 年測試的劃分方式，後續可以使用滾動窗口評估，觀察模型在不同年份訓練和測試時的性能變化。如果某些年份出現明顯性能下降，還可以進一步分析道路安全政策、車輛安全技術或事故記錄方式變化對模型的影響。

我們認為雖然當前結果說明事故初報信息具有一定預測價值，但 Fatal 類識別仍受限於類別稀缺和關鍵變數缺失。未來改進的重點不應只是繼續堆疊複雜模型，而應更多關注特徵品質、少數類學習策略和不同事故場景下的錯誤機制。

## 參考文獻

- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.  
<https://doi.org/10.1023/A:1010933404324>
- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357. <https://doi.org/10.1613/jair.953>
- Department for Transport. (2025). Road safety open data. GOV.UK.  
<https://www.gov.uk/government/statistical-data-sets/road-accidents-safety-data>
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189–1232.  
<https://doi.org/10.1214/aos/1013203451>
- He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284.  
<https://doi.org/10.1109/TKDE.2008.239>
- Hubert, L., & Arabie, P. (1985). Comparing partitions. *Journal of Classification*, 2(1), 193–218. <https://doi.org/10.1007/BF01908075>
- Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. In *Proceedings of the IEEE International Conference on Computer Vision* (pp. 2980–2988). <https://doi.org/10.1109/ICCV.2017.324>
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems* (Vol. 30). Curran Associates, Inc.
- MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. In L. M. Le Cam & J. Neyman (Eds.), *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability* (Vol. 1, pp. 281–297). University of California Press.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and



validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65. [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)

Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3), Article e0118432. <https://doi.org/10.1371/journal.pone.0118432>

World Health Organization. (2018). Global status report on road safety 2018. <https://www.who.int/publications/i/item/9789241565684>

## 小組成員分工

| 姓名  | 學號           | 貢獻                                                                                                                                     |
|-----|--------------|----------------------------------------------------------------------------------------------------------------------------------------|
| 呂維懿 | D23090600351 | 負責結果分析與報告撰寫，包括背景與問題定義、模型選擇說明、評估結果解釋、錯誤分析、結論與未來工作撰寫，整理參考文獻、統一圖表標題和章節邏輯，並參與實驗結果核對。                                                       |
| 李東曉 | D23090600680 | 負責模型實現與實驗運行，包括 K-Means 聚類、層次聚類對比、Logistic Regression、Random Forest、HistGradientBoosting 訓練，不平衡處理消融實驗、超參數調優、測試集評估、時間 holdout 實驗及主要圖表生成。 |
| 李柏熹 | D23090600127 | 負責研究問題設定、預測場景設計與數據預處理方案，包括 STATS19 三表關係分析、事故表與車輛表整合、傷亡表排除依據、缺失值與異常值處理、防數據洩漏原則設計，並參與最終特徵集核對。                                            |

本項目由三名成員共同完成，三人在選題、實驗方案討論和最終報告修改階段均有參與，交叉驗證貢獻相同。